

CNC 설비 정상 / 불량 판별

UCI AI4I 2020 Predictive Maintenance 데이터 기반 이진분류

설비 센서값으로 고장 여부를 판별하는 미니 프로젝트

데이터 수집 → 탐색적 데이터 분석(EDA) → 모델링 1차·2차·3차 → 데스크톱 UI

GitHub · https://github.com/hmy7788/python_data_analyze




팀 구성 & 역할 분담

이름	역할
허민엽	크롤링 및 UI 설계 ①
최나연	크롤링 및 UI 설계 ②
이하연	데이터 분석 및 모델링 ①
최혁	데이터 분석 및 모델링 ②

4인 미니 프로젝트 · 데이터팀(분석·모델링) + 애플리케이션팀(크롤링·UI)으로 분담

배경 – 예지보전과 AI4I 2020

- 예지보전(Predictive Maintenance):
 - 설비가 고장 나기 전에 센서 신호로 미리 잡아내는 것
 - 생산 중단 감소 및 유지보수 비용 절감 효과
- AI4I 2020 Predictive Maintenance Dataset — UCI Machine Learning Repository 공개
 - 밀링 머신 공정 데이터
- 규모: 10,000행 × 14열, 결측치·중복행 없음, 이진분류 (정상 / 불량)
- 데이터 선정 이유
 - PHM(Predictive Health Management) 개념을 실제 데이터에 적용하기 위해 선정
 - 실제 제조 설비에서 수집 가능한 온도, 회전속도, 토크, 공구 마모 등의 센서 데이터를 포함하고 있어 예지보전 분석에 적합








컬럼 구성 — 14개 열의 역할

컬럼	설명	역할
식별번호 (UDI, Product ID)	일련번호, 제품 ID	식별자 → 제거
품질 등급 (Type)	L 저가 / M 중가 / H 고가	입력 (원핫 인코딩)
대기 온도 (Air / Process temperature [K])	작업장 실내 온도	입력
공정 온도 (Process temperature [K])	가공부 온도	입력
회전 속도 (Rotational speed [rpm])	회전 속도	입력
토크 (Torque [Nm])	회전력	입력
공구 누적 사용 시간 (Tool wear [min])	공구가 절삭에 사용된 누적 시간(분)	입력
고장 여부 (Machine failure)	0 정상 / 1 불량	★ 타겟
TWF / HDF / PWF / OSF / RNF	세부 고장 모드	data 누수 위험 → 제거


→ 타겟에서 파생된 값이라 train에 쓰면 data 누수

데이터 품질 & 변수 분포




- 결측치 0 · 중복행 0 — 정제된 데이터셋
- Air / Process temperature: 정규분포에 근접
- Rotational speed: 오른쪽 꼬리가 김 (고속 구간 일부)
- Torque: 전체적으로 정규분포
- Tool wear: 0~253분, 비교적 균등 (주기적 교체)

타겟 — 클래스 불균형 & Type별 고장률



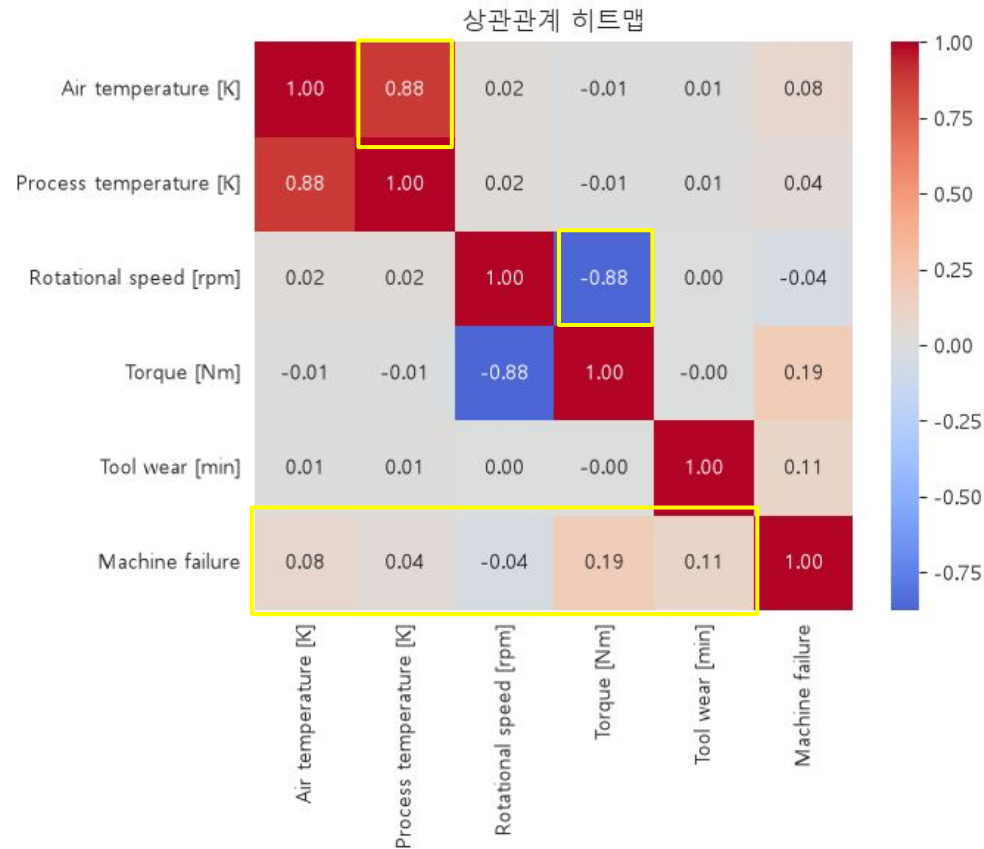
정상 9,661 (96.6%) vs 불량 339 (3.39%)



Type별 고장률 — L 3.92% > M 2.77% > H 2.09%


- 극심한 불균형: '전부 정상' 베이스라인 정확도 96.6% → accuracy는 지표로 무의미
→ 불량(1) 클래스의 **정밀도, 재현율, F1** 를 중점적으로 봐야함
- 저품질(L)일수록 고장률↑ — 내구성·공차가 낮은 것으로 해석

Feature간 상관관계



- 기온 ↔ 공정온도: +0.88 (강한 양의 상관관계)
- 회전속도 ↔ 토크: -0.88 (강한 음의 상관관계)
 - 다중 공선성 주의: 서로 겹치는 정보를 가진 변수 쌍
 - 선형모델에서 계수가 불안정해지고 어느 변수 묶었는지 갈라지지 않음
- Machine failure 상관관계
 - Torque 0.19 > Tool wear 0.11 > Air temp 0.08 > . . .
 - 개별 변수로는 고장을 설명하는 힘이 약함
 - 파생피처가 필요할듯함.

고장 여부별 변수 분포 → 핵심 가설



- 온도 자체(Air/Process)는 정상·불량 차이가 작음
- 고장(1) 시 토크값 높고, 회전속도 낮은 경향
- Tool Wear은 고장일때 정상에 비해 높은 경향

학습에 넣기까지 . . .

- 다중공성선이 높음 → 선형모델 대신 **트리 모델**로 실험
 - RandomForest, XGBoost, lightGBM 3가지 모델로 실험!

선형모델	트리모델
변수 간 관계를 직선 형태로 학습	변수 간 복잡한 비선형 관계 학습
변수 간 상관성 영향이 큼	상관성 영향이 비교적 적음
해석이 쉬움	복잡한 패턴 학습에 유리

모델	특징
Random Forest	안정적, 과적합에 강함
XGBoost	이전 모델의 오차를 계속 보완하면서 학습, 학습 시간 김
LightGBM	학습 속도가 빠르고 성능도 우수, 데이터 적을시 과적합 가능

- train / test = 8 : 2, stratify=y 로 정상/불량 비율 유지

Train (9661)	정상	7688
	불량	1973
Test (339)	정상	271
	불량	68

1차 — Baseline (model_1.ipynb)

- 원본 변수만 + 파생변수 없음
- 모델 3종 단순 비교: RandomForest, XGBoost, LightGBM

모델	정확도	정밀도	재현율	F1-score
Random Forest	0.942	0.35	0.85	0.50
XGBoost	0.984	0.91	0.59	0.71
LightGBM	0.985	0.89	0.62	0.73

- RF는 재현율 0.85로 높지만 정밀도 0.35 (정상을 불량으로 오탐 99건)
- XGBoost/LightGBM은 정밀도 0.9대지만 재현율 0.6 전후 - 실제 불량의 약 40%를 놓침
→ 원본 변수만으로는 정밀도와 재현율을 동시에 잡는 모델이 없음 → 2차로
- F1-Score 기준 lightGBM이 가장 우수

2차 — 파생 피처 7개 + 하이퍼파라미터 튜닝 (model_2.ipynb)

① 센서값을 파생 피처 생성

파생 피처	내용	계산식
Power	회전속도와 토크를 결합하여 실제 설비 부하를 표현	회전속도 × 토크
Temp_diff	가공 과정에서 발생하는 열 증가량 표현	공정온도 - 기온
Power_wear	높은 부하와 공구 마모를 함께 반영	Power × 공구마모
Torque_per_RPM	회전속도 대비 토크 비율을 통해 부하 상태 표현	토크 ÷ (회전속도 + 1)
Torque_wear	공구 마모에 따른 토크 증가 특성 반영	토크 × 공구마모
Temp_Torque	열과 부하를 동시에 고려하여 이상 상태 표현	Temp_diff × 토크
Temp_ratio	외기 대비 공정 온도 상승 비율 표현	공정온도 ÷ 기온

② RandomForest 튜닝

- RandomizedSearchCV
 - Hyperparameter 후보 중 일부만 무작위로 뽑아서 서칭
- 최적 파라미터
 - `n_estimators=300`, `max_depth=None`,
 - `min_samples_leaf=2`, `max_features=log2`,
 - `class_weight={0:1, 1:8}`
- CV 재현율(best) 0.995

2차 — 파생 피처 7개 + 하이퍼파라미터 튜닝 (model_2.ipynb)

모델 (파생 피처 + 하이퍼파라미터 튜닝)	정확도	정밀도	재현율	F1-score
Random Forest	0.88	0.22	0.95	0.35
XGBoost	0.98	0.57	0.82	0.67
lightGBM	0.98	0.61	0.79	0.69

성능 분석

- **Random Forest**는 1차에 비해 F1이 0.2 감소
- **XGBoost, lightGBM**은 1차에 비해 F1이 0.04 감소
- F1-Score 기준 lightGBM이 가장 우수

모델들의 전체적인 분석

- 3개의 모델 모두 피처 엔지니어링 및 하이퍼파라미터 서칭이 큰 효과가 없었고 오히려 오버피팅으로 인해 **F1-Score**가 떨어진것으로 판단됨

3차 — 위험구간(risk_zone) 피쳐 (model_3.ipynb, 최종)

우리의 목표: **F1-Score**를 늘리자!

- 문제: 현실적으로 도메인 지식도 부족하고, EDA에서 좋은 인사이트를 얻을수가 없었음!
- 해결: 그럼 직접 서치해서 도메인 지식을 찾아보자!



UCI 공식 문서에서 해당 설비에 대한 도메인 지식을 찾을 수 있었음!

The machine failure consists of five independent failure modes

tool wear failure (TWF): the tool will be replaced or fail at a randomly selected tool wear time between 200 ~ 240 mins (120 times in our dataset). At this point in time, the tool is replaced 69 times, and fails 51 times (randomly assigned).

heat dissipation failure (HDF): heat dissipation causes a process failure, if the difference between air- and process temperature is below 8.6 K and the tool's rotational speed is below 1380 rpm. This is the case for 115 data points.

power failure (PWF): the product of torque and rotational speed (in rad/s) equals the power required for the process. If this power is below 3500 W or above 9000 W, the process fails, which is the case 95 times in our dataset.


overstrain failure (OSF): if the product of tool wear and torque exceeds 11,000 minNm for the L product variant (12,000 M, 13,000 H), the process fails due to overstrain. This is true for 98 datapoints.

random failures (RNF): each process has a chance of 0,1 % to fail regardless of its process parameters. This is the case for only 5 datapoints, less than could be expected for 10,000 datapoints in our dataset.


3차 — 위험구간(risk_zone) 피쳐 (model_3.ipynb, 최종)

파생 피쳐	공식
hdf_zone	1 if 온도차 > 8.6K and 회전속도 < 1380 else 0
pwf_zone	1 if 동력 < 3500 or 동력 > 9000 else 0
osf_zone	1 if 토크 * 공구 누적 사용 시간 > 타입별 임계값 (L=11k, M=12K, H=13K) else 0
high_wear	1 if 공구 누적 사용 시간 > 200 else 0
risk_zone_count	hdf_zone + pwf_zone + osf_zone + high_wear (위험존에 대한 카운팅 값)

3차 — 위험구간(risk_zone) 피쳐 (model_3.ipynb, 최종)



1. 원본 변수 vs 파생변수(zone) — 불량 예측력 비교



2. 위험구간 개수 vs 실제 불량률

- risk_zone_count 컬럼이 불량 예측에 대해 아주 높은 상관관계를 가짐 (약 0.64)
- 다른 위험 zone에 대해서도 약 0.51의 상관관계를 가짐


- risk_zone_count가 1일때 약 20프로의 설비만이 고장임을 알 수 있음
- risk_zone_count가 2이상이면 사실상 고장임을 알 수 있음

3차 실험 모델 3종 비교


모델 (도메인 지식 적용)	정확도	정밀도	재현율	F1-score
Random Forest	0.994	1.000	0.838	0.912
XGBoost	0.992	0.934	0.838	0.884
lightGBM	0.994	0.966	0.838	0.898

- 3개 모델 1차, 2차 실험에 비해 전부 F1 상승
 - 1차: RF +0.185 / XGB +0.128 / LGBM +0.098
 - 2차: RF +0.56 / XGB +0.11 / LGBM +0.2
- 특정 알고리즘의 과적합이 아닌 일반적 효과

Baseline vs 3차 모델 3종 비교 그래프



3차 모델 3종 confusion matrix 비교




- Recall은 모두 같지만 Precision에서 차이가 남 (RF > lightGBM > XGBoost)
- F1-Score상 가장 우수한 모델은 RF -> 최종 모델로 선정


1, 2, 3차 모델 3종 비교 그래프

	모델	정확도	정밀도	재현율	F1-Score
1차 실험 (baseline)	RandomForest	0.942	0.35	0.85	0.50
	lightGBM	0.985	0.89	0.62	0.73
	XGBoost	0.984	0.91	0.59	0.71
2차 실험 (파생피쳐 + 하이퍼파라미터 서치)	RandomForest	0.88	0.22	0.95	0.35
	lightGBM	0.98	0.61	0.79	0.69
	XGBoost	0.98	0.57	0.82	0.67
3차 실험 (도메인 지식 적용)	RandomForest	0.994	1.000	0.838	0.912
	lightGBM	0.992	0.934	0.838	0.884
	XGBoost	0.994	0.966	0.838	0.898

아키텍처 — src/UI/ 4개 모듈



모듈	역할
main.py	위젯 조립 및 UI 제공
visualizer.py	CSV → matplotlib Figure (그래프 12종)
crawler.py	검색어 → 네이버 뉴스 HTML → 기사 목록
model_predictor.py	저장된 모델 로드, 입력 → 예측/지표



기능 — 데스크톱 앱 (Tkinter)



① 전체 데이터 한눈에 보기



③ 모델 입력 · 예측



② 모델 학습 결과

- 좌측 3개 탭
 - ① 전체 데이터: 요약 카드 4 + 그래프 12
 - ② 모델 훈련 결과: 지표 카드 5 + 비교 그래프
 - ③ 모델 입력 → 정상/불량 + 불량 확률 예측
- 입력 6개 (Type · 기온 · 공정온도 · 회전속도 · 토크 · 마모)
 - 15개 피쳐 (위험구간 포함)로 변환 후 예측
- 우측: 네이버 뉴스 크롤링
 - 그래프 카드 클릭 시 그 인사이트 키워드로 재검색
 - EDA 결과 ↔ 실제 업계 뉴스 교차검증

마무리 — 핵심 요약

- EDA에서 얻은 가설: 개별 변수 값보다 '실제 고장 판정에 쓰이는 조합'이 강한 신호
- "모델을 더 잘 튜닝"(1·2차)보다 "도메인 지식을 피쳐로 주입"(3차)이 결정적 — F1 0.50 → 0.912
- 불균형 데이터는 정확도 판단 금지 → 정밀도 · 재현율 · F1 함께 확인
- 학습된 모델을 저장하여 UI와 연동 → 데스크톱 UI에서 실시간 예측 기능 구현

GitHub · https://github.com/hmy7788/python_data_analyze

UI 시연 영상 · [시연영상](#)